

FONDAMENTAUX DE L'APPRENTISSAGE AUTOMATIQUE

8INF867 (MS)

UNIVERSITÉ DU QUÉBEC À RIMOUSKI

DÉPARTEMENT DE MATHÉMATIQUES, D'INFORMATIQUE ET DE GÉNIE

RAPPORT

Étude expérimentale d'un algorithme d'apprentissage supervisé (SVM)

ÉTUDIANT(E) :
Pier-Luc Dupéré

PROFESSEUR :
Yacine Yaddaden, Ph. D.

Date : 24 octobre 2026

Table des matières

1 Introduction **3**

2 Choix, exploration et compréhension des données **3**

3 Prétraitement et représentation des données **4**

4 Sélection / réduction de dimension **5**

5 Compréhension et recherche sur l'algorithme **6**

6 Protocole de validation et métriques **8**

7 Présentation et interprétation des résultats **9**
7.1 Noyau linéaire (linear) 9
7.2 Noyau polynomial (poly) 11
7.3 Noyau RBF 13
7.4 Noyau sigmoïde (sigmoid) 15
7.5 Analyses des résultats 16

8 Bilan critique de l'algorithme **17**

1 Introduction

Ce travail pratique étudie expérimentalement un algorithme d'apprentissage supervisé, le SVM, appliqué à la classification d'images IRM. Il consiste à construire un pipeline complet, à analyser les principaux paramètres du modèle et à évaluer son comportement au moyen de différentes expériences. L'objectif est de comprendre et d'expliquer les résultats obtenus, au-delà de la seule recherche de bonnes performances.

Notes

La rédaction et la mise en forme de ce document ont été réalisées avec LaTeX et Visual Studio Code. Les outils de correction orthographique (Code Spell checker) et d'auto-complétion (IntelliSense) ont été utilisés comme aide à la rédaction. Il peut donc y avoir une forme d'intelligence artificielle qui aide a la redaction.

2 Choix, exploration et compréhension des données

Le projet OASIS[1] met gratuitement à la disposition des chercheurs des données d'imagerie du cerveau. On a utiliser la base de données OASIS 1 qui contient des images à résonance magnétique ayant été diagnostiquer pas des médecins professionnels. Dans cette base de données, on retrouve le résultats des patients et qui sont classifier en 4 catégories. De plus, la base de données contient d'autres informations et évaluations, comme les résultats de tests cognitifs et l'âge des patients etc.

3 Prétraitement et représentation des données

En ce qui concerne la préparation des données, on a extrait des coupes axial du cerveau de chaque patients. Pour faire la sélection des tranches, on a utiliser un logiciel appeler XMedCon[2]. On a pris 25 coupes par échantillon. Les coupes de 80 à 104 inclusivement de chaque fichier hdr.

Dans ce travail, seulement 15 échantillons pour chacune des trois catégories :

- Démence légère (Mild Demented)
- Sans démence (Non Demented)
- Démence très légère (Very Mild Demented)

Le code pré-traite une image IRM du cerveau. Il la convertit en niveaux de gris, applique un flou gaussien, puis utilise le seuillage d :Otsu et des opérations morphologiques pour nettoyage de l'image. Il repère ensuite les contours situés dans la zone centrale afin de créer un masque du cerveau. Ce masque est appliqué à l'image, puis la zone obtenue est recadrée et redimensionnée en 128×128 pixels pour faciliter son analyse. On applique cela a tout les IRM et on sauvegarde le tout sous forme de png.

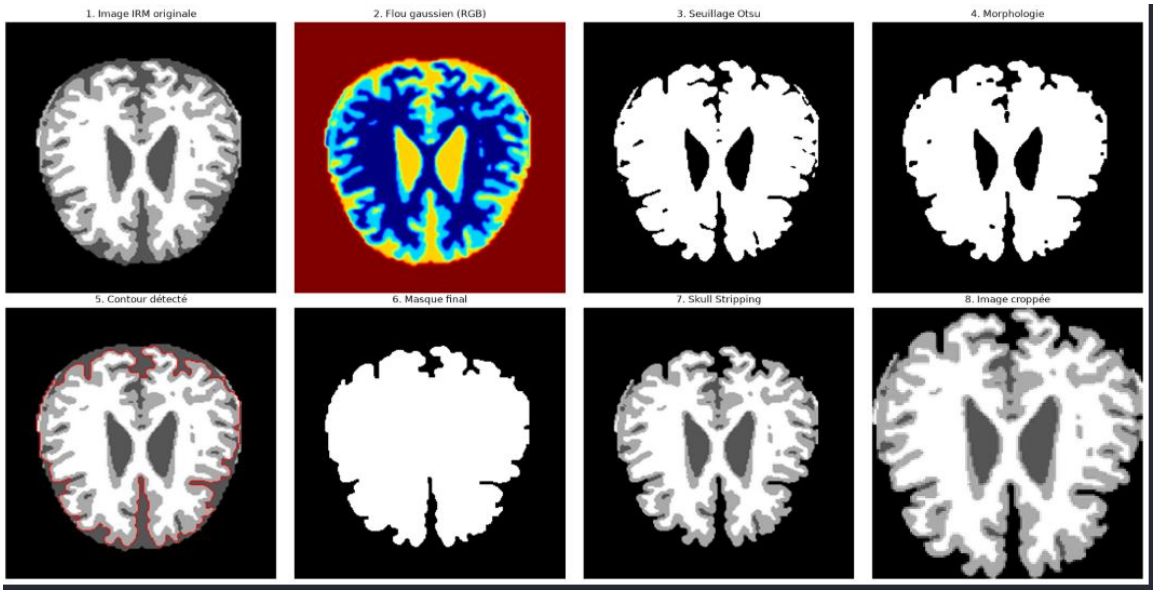


FIGURE 1 – Étapes du prétraitement des images IRM

4 Sélection / réduction de dimension

Le Local Binary Pattern (LBP) de la librairie scikit-image[3] est utilisé afin de réduire et sélectionner l'information des IRM. Cette fonction compare les pixels voisins au pixel central. Cela forment un motif binaire qui représente la texture autour du pixel. On peut ensuite utiliser les motifs obtenus pour générer un histogramme pour caractériser et classer les textures. Dans notre étude, la classification des textures revient à classer les échantillons selon leur catégorie.

Les parameters de la fonction sont les suivants :
- P=8 (nombre de point)
- R=3 (rayon)
- method="default" (changements d'intensité en niveaux de gris sans rotations.)

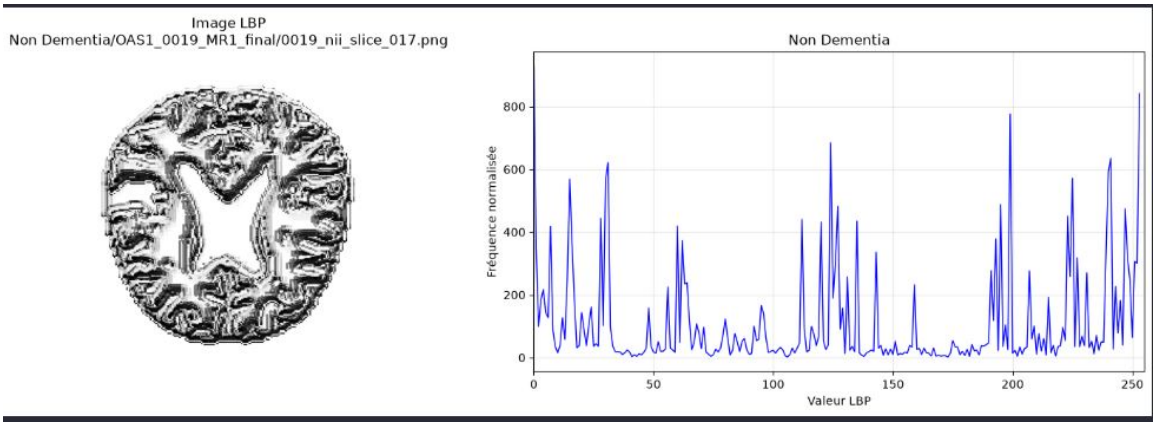


FIGURE 2 – À gauche : représentation de l'image LBP ; à droite : histogramme correspondant

De plus, une réduction de dimension par analyse en composantes principales de type PCA est appliquée aux données dans le pipeline[4] d'execution.
Les parameters du PCA :
- `n_components=0.95` (% de la variance des données conservée)
- `svd_solver=auto` (méthode de calcul utilisé)
- `power_iteration_normalizer=auto`

5 Compréhension et recherche sur l'algorithme

```python
from sklearn.decomposition import PCA
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVC

# === Pipeline SVM  LAISSEZ PAR DEFAULT ===
# https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC.html
svm_pipeline = Pipeline([
    ("scaler", StandardScaler()),
    ("PCA", PCA(
        n_components=0.95,
        svd_solver="auto",
        power_iteration_normalizer="auto",
    )),
    ("svm", SVC(
        kernel="linear",
        C=10,
        gamma="scale",
        coef0=0.0,
    ))
])
```

FIGURE 3 – Pipeline réalise une classification avec un SVM

Dans l'image ci-dessus, on peut voir un pipeline qui standardise les caractéristiques et puis qui réduit leur nombre en conservant un pourcentage de la variance. Par la suite, on utilise un SVM pour classer les échantillons.
Dans le tableau ci-dessous, il y a un résumé synthèse de tout les principale hyperparamètres. On peut voir la fonction que chacun de chacun ainsi que leur effets sur l'hyperplan qui segmente les échantillons. De plus, les valeurs typique qui vont être tester plus tard.

TABLE 1 – Principaux hyperparamètres d'un SVM [5]

Hyperparamètre	**Fonction**	**Effets**	**Valeurs**
`kernel`	Type de noyau utilisé	Détermine la forme de la frontière de décision	`linear`, `poly`, `rbf`, `sigmoid`
`C`	Pénalisation des erreurs de classification	Une faible valeur favorise une marge plus large et peut entraîner du sous-apprentissage ; une valeur élevée pénalise davantage les erreurs et peut favoriser le sur-apprentissage	0.01 à 100
`gamma`	Inverse du rayon d'influence, notamment pour le noyau RBF	Une faible valeur produit une frontière plus lisse ; une valeur élevée peut la rendre plus complexe	0.001 à 10.0
`degree`	Degré du polynôme utilisé par le noyau polynomial	Un degré plus élevé permet une frontière de décision plus flexible	2 à 5
`coef0`	Terme constant des noyaux polynomial et sigmoid	Influence la forme du noyau, notamment dans le cas du noyau polynomial	0.0 à 1.0

6 Protocole de validation et métriques

Afin de cherche la meilleure combinaison de paramètres pour un modèle. On a utiliser la librairie GridSearchCV[6]. Elle teste les combinaisons indiquées et évalue chacune avec une validation croisée, puis sélectionne celle qui obtient le meilleur score.

```
        "svm__gamma": ["scale", "auto"],
        # "svm__gamma": [0.1, 0.5, 0.75, 0.9, 1, 1.1, 1.5, 2, 10],
        "svm__degree": [2, 3, 4, 5],
        "svm__coef0": [0, 0.1, 0.25, 0.5, 0.75, 1],
    },
    {
        "PCA__n_components": [0.80, 0.85, 0.90, 0.95, 0.99],
        "svm__kernel": ["sigmoid"],
        "svm__C": [0.1, 0.5, 0.75, 0.9, 1, 1.1, 1.5, 2, 10],
        "svm__gamma": ["scale", "auto"],
        # "svm__gamma": [0.1, 0.5, 0.75, 0.9, 1, 1.1, 1.5, 2, 10],
        "svm__coef0": [0, 0.1, 0.25, 0.5, 0.75, 1],
    },
]

grid_search = GridSearchCV(
    estimator=svm_pipeline,
    param_grid=param_grid,
    scoring="accuracy",
    cv=cv,
    n_jobs=-1,
    refit=True,
    verbose=0
)

grid_search.fit(x_train, y_train)
best_svm_pipeline = grid_search.best_estimator_
```

FIGURE 4 – Utilisation de GridSearchCV

Pour chaque combinaison, GridSearchCV évalue les performances en validation croisée (cv), avec l'accuracy comme mesure. Il teste chacune des combinaisons répétée pour les différentes validations croisées avec StratifiedKFold[7]. Cela signifie que chaque combinaison de paramètres sera évaluée sur ces 10 découpages, puis comparée selon son accuracy moyenne.
Après l'entrainment du model, on prend le meilleur résultat avec les meilleurs para-

mètres.
Pour finir, le meilleur modèle est évalué sur les données de test, qu'il n'a pas vues pendant son entraînement. Il prédit la classe de chaque échantillon. Ces prédictions sont comparées aux vraies classes pour calculer son exactitude et produire des documents afin de faciliter l'analyse des performances du modèle sur les données de test.

7 Présentation et interprétation des résultats

7.1 Noyau linéaire (linear)

		precision	recall	f1-score	support
1	Mild Demented	0.5373134328358209	0.5373134328358209	0.5373134328358209	67.0
2	Non Dementia	0.631578947368421	0.6	0.6153846153846154	60.0
3	Very Mild Demented	0.42857142857142855	0.4528301886792453	0.44036697247706424	53.0
4	accuracy	0.5333333333333333	0.5333333333333333	0.5333333333333333	0.5333333333333333
5	macro avg	0.5324879362585568	0.5300478738383553	0.5310216735658335	180.0
6	weighted avg	0.5367167919799498	0.5333333333333333	0.5347918136908963	180.0

1	36	9	22
2	14	36	10
3	17	12	24

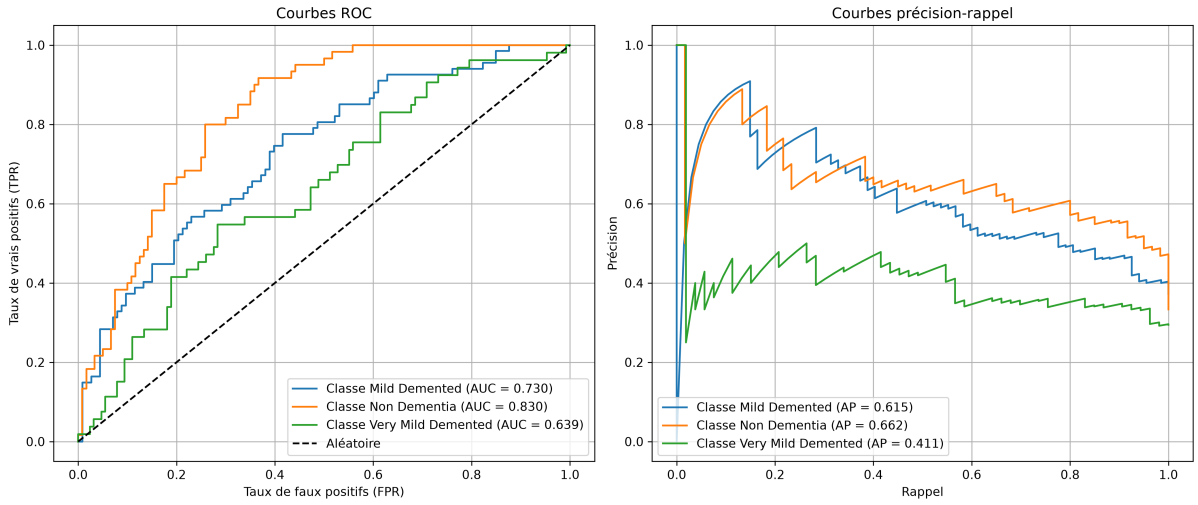


FIGURE 5 – Résultats du noyau linéaire

La matrice de confusion montre que le modèle classe correctement 36 images *Mild Demented*, 36 images *Non Dementia* et 24 images *Very Mild Demented*. Sur les 180 images évaluées, 96 sont correctement classées, ce qui correspond à une exactitude de 53,3 %.

Le rapport de classification indique que la classe *Non Dementia* obtient le meilleur F1-score (0,615), tandis que la classe *Very Mild Demented* obtient le plus faible (0,440). Le F1-score macro est de 0,531 et le F1-score pondéré est de 0,535.

La courbe ROC montre que le modèle distingue le mieux la classe *Non Dementia* (AUC = 0,830), suivie de *Mild Demented* (0,730). La classe *Very Mild Demented* est la moins bien distinguée (0,639).

La courbe précision-rappel confirme cette tendance : la moyenne de precision (AP) est de 0,662 pour *Non Dementia*, de 0,615 pour *Mild Demented* et de 0,411 pour *Very Mild Demented*. Le modèle obtient donc ses meilleurs résultats pour *Non Dementia* et ses résultats les plus faibles pour *Very Mild Demented*.

Les paramètres retenus pour le modèle SVM sont les suivants :

- Noyau : linéaire (*linear*)
- Paramètre de régularisation C : 0,1
- Variance conservée par la PCA : 80 %

Aucun paramètre γ ni *coef0* n'est indiqué pour ce noyau.

7.2 Noyau polynomial (poly)

		precision	recall	f1-score	support
1	Mild Demented	0.8484848484848485	0.835820895522388	0.8421052631578947	67.0
2	Non Dementia	0.8709677419354839	0.9	0.8852459016393442	60.0
3	Very Mild Demented	0.7884615384615384	0.7735849056603774	0.780952380952381	53.0
4	accuracy	0.8388888888888889	0.8388888888888889	0.8388888888888889	0.8388888888888889
5	macro avg	0.835971376293957	0.8364686003942552	0.8361011819165399	180.0
6	weighted avg	0.8383056161281968	0.8388888888888889	0.8384793495578655	180.0

1	56	4	7
2	2	54	4
3	8	4	41

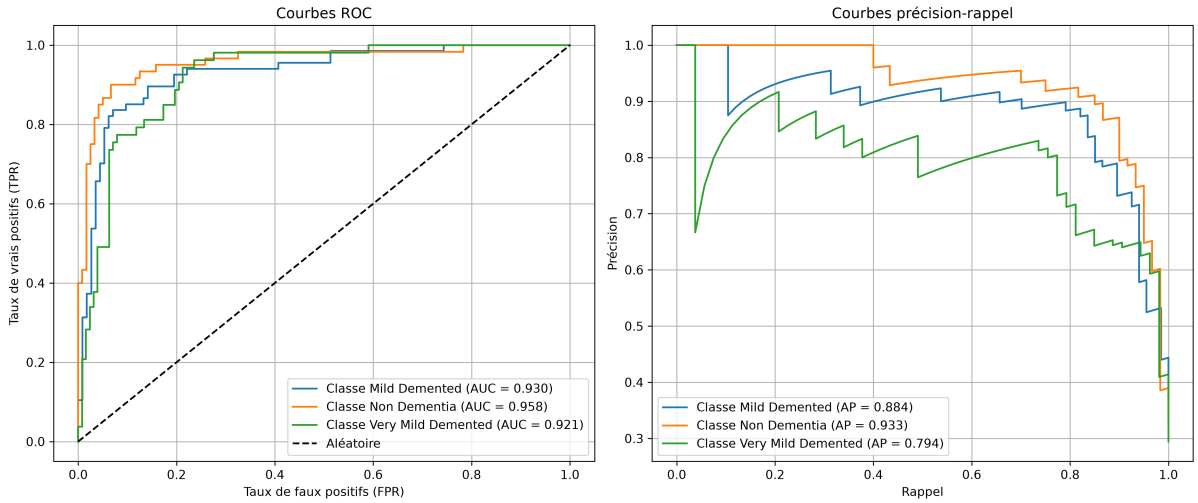


FIGURE 6 – Résultats du noyau polynomial

La matrice de confusion montre que le modèle classe correctement 56 images *Mild Demented*, 54 images *Non Dementia* et 41 images *Very Mild Demented*. Sur les 180 images évaluées, 151 sont correctement classées, ce qui correspond à une exactitude de 83,9 %.

Le rapport de classification indique que la classe *Non Dementia* obtient le meilleur F1-score (0,9), tandis que la classe *Very Mild Demented* obtient le plus faible (0,774). Le F1-score macro est de 0,836 et le F1-score pondéré est de 0,839.

La courbe ROC montre que le modèle distingue le mieux la classe *Non Dementia* (AUC = 0,958), suivie de *Mild Demented* (0,930). La classe *Very Mild Demented* est la moins bien distinguée (0,921).

La courbe précision-rappel confirme cette tendance : la moyenne de precision (AP) est de 0,933 pour *Non Dementia*, de 0,884 pour *Mild Demented* et de 0,794 pour *Very Mild*

Demented. Le modèle obtient donc ses meilleurs résultats pour *Non Dementia* et ses résultats les plus faibles pour *Very Mild Demented*.

Les paramètres retenus pour le modèle SVM sont les suivants :

- Noyau : linéaire (*linear*)
- Paramètre de régularisation C : 0,1
- Variance conservée par la PCA : 80 %
- Paramètre γ : *auto*
- Paramètre *coef0* : 0,1

Les meilleurs résultats ont été obtenus avec les valeurs automatiques de γ (*auto* et *scale*), plutôt qu'avec les valeurs numériques prédéfinies.

7.3 Noyau RBF

		precision	recall	f1-score	support
1	Mild Demented	0.8461538461538461	0.8208955223880597	0.8333333333333334	67.0
2	Non Dementia	0.8	0.8666666666666667	0.832	60.0
3	Very Mild Demented	0.76	0.7169811320754716	0.7378640776699029	53.0
4	accuracy	0.8055555555555556	0.8055555555555556	0.8055555555555556	0.8055555555555556
5	macro avg	0.8020512820512821	0.8015144403767326	0.8010658036677455	180.0
6	weighted avg	0.8054017094017095	0.8055555555555556	0.8047784969435454	180.0

1	55	5	7
2	3	52	5
3	7	8	38

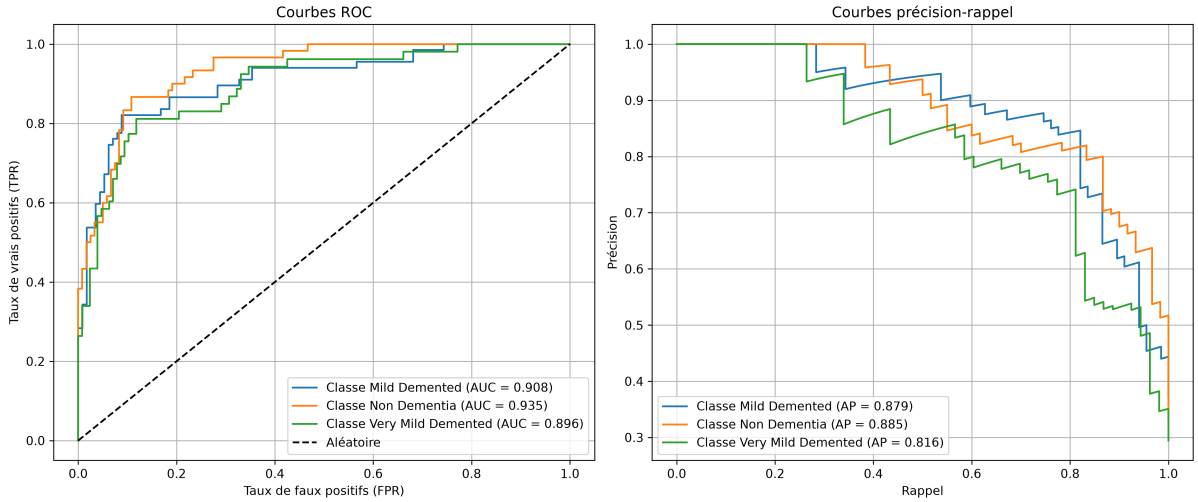


FIGURE 7 – Résultats du noyau RBF

La matrice de confusion montre que le modèle classe correctement 55 images *Mild Demented*, 52 images *Non Dementia* et 38 images *Very Mild Demented*. Sur les 180 images évaluées, 145 sont correctement classées, ce qui correspond à une exactitude de 80,6 %.

Le rapport de classification indique que la classe *Mild Demented* obtient le meilleur F1-score (0,833), tandis que la classe *Very Mild Demented* obtient le plus faible (0,738). Le F1-score macro est de 0,801 et le F1-score pondéré est de 0,805.

La courbe ROC montre que le modèle distingue le mieux la classe *Non Dementia* (AUC = 0,935), suivie de *Mild Demented* (0,908). La classe *Very Mild Demented* est la moins bien distinguée (0,896).

La courbe précision-rappel confirme cette tendance : la moyenne de precision (AP) est de 0,885 pour *Non Dementia*, de 0,879 pour *Mild Demented* et de 0,816 pour *Very Mild Demented*. Le modèle obtient donc ses meilleurs résultats pour *Non Dementia* et ses ré-

sultats les plus faibles pour *Very Mild Demented*.

Les paramètres retenus pour le modèle SVM sont les suivants :

- Noyau : linéaire (*RBF*)
- Paramètre de régularisation C : 2,0
- Variance conservée par la PCA : 80 %
- Paramètre γ : *auto*

Les meilleurs résultats ont été obtenus avec les valeurs automatiques de γ (*auto* et *scale*), plutôt qu'avec les valeurs numériques prédéfinies. Aucun paramètre *coef0* n'est indiqué pour ce noyau.

7.4 Noyau sigmoïde (sigmoid)

		precision	recall	f1-score	support
1	Mild Demented	0.5483870967741935	0.5074626865671642	0.5271317829457365	67.0
2	Non Dementia	0.576271186440678	0.5666666666666667	0.5714285714285714	60.0
3	Very Mild Demented	0.4406779661016949	0.49056603773584906	0.4642857142857143	53.0
4	accuracy	0.5222222222222223	0.5222222222222223	0.5222222222222223	0.5222222222222223
5	macro avg	0.5217787497721887	0.5215651303232266	0.5209486895533407	180.0
6	weighted avg	0.5259674381872304	0.5222222222222223	0.5233927033345639	180.0

1	34	14	19
2	12	34	14
3	16	11	26

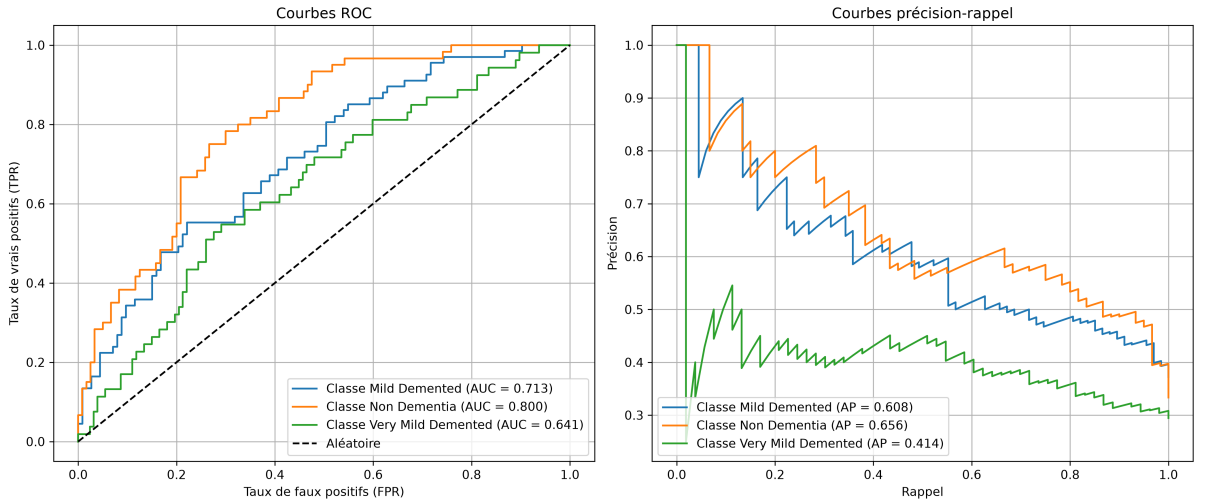


FIGURE 8 – Résultats du noyau sigmoid

La matrice de confusion montre que le modèle classe correctement 34 images *Mild Demented*, 34 images *Non Dementia* et 26 images *Very Mild Demented*. Sur les 180 images évaluées, 151 sont correctement classées, ce qui correspond à une exactitude de 46,7 %.

Le rapport de classification indique que la classe *Non Dementia* obtient le meilleur F1-score (0,567), tandis que la classe *Very Mild Demented* obtient le plus faible (0,491). Le F1-score macro est de 0,521 et le F1-score pondéré est de 0,523.

La courbe ROC montre que le modèle distingue le mieux la classe *Non Dementia* (AUC = 0,800), suivie de *Mild Demented* (0,713). La classe *Very Mild Demented* est la moins bien distinguée (0,641).

La courbe précision-rappel confirme cette tendance : la moyenne de precision (AP) est de 0,656 pour *Non Dementia*, de 0,608 pour *Mild Demented* et de 0,414 pour *Very Mild Demented*. Le modèle obtient donc ses meilleurs résultats pour *Non Dementia* et ses ré-

sultats les plus faibles pour *Very Mild Demented*.

Les paramètres retenus pour le modèle SVM sont les suivants :

- Noyau : linéaire (*linear*)
- Paramètre de régularisation C : 0,5
- Variance conservée par la PCA : 90 %
- Paramètre γ : *scale*
- Paramètre *coef0* : 0,0

Les meilleurs résultats ont été obtenus avec les valeurs automatiques de γ (*auto* et *scale*), plutôt qu'avec les valeurs numériques prédéfinies.

7.5 Analyses des résultats

Les résultats montrent que le choix du noyau influence fortement les performances du SVM. Le noyau polynomial obtient les meilleurs résultats suivi du noyau RBF. Ces deux noyaux distinguent mieux les classes que les noyaux linéaire et sigmoïde. Donc leur performances restent modestes.

Pour les quatre modèles, la classe Very Mild Demented est la plus difficile à reconnaître. Elle présente les scores les plus faibles, ce qui suggère une confusion plus importante avec les autres classes. À l'inverse, la classe Non Dementia est généralement mieux distinguée. même si le noyau RBF obtient son meilleur F1-score pour Mild Demented.

Parmi les modèles évalués avec la grille de paramètre définit dans le code, le noyau polynomial constitue le meilleur choix. Cependant, une exploration supplémentaire sur les hyperparamètres serait nécessaire pour choisir quelle est le meilleur noyau.

8 Bilan critique de l'algorithme

Les méthodes à noyaux offrent une grande flexibilité et permettent de modéliser des relations non linéaires, même avec des jeux de données de taille modérée. Elles reposent aussi sur des bases théoriques solides et peuvent être adaptées à différents types de données.

Elles présentent toutefois des limites : leur coût de calcul augmente fortement avec le nombre d'échantillons, leurs performances dépendent du réglage des hyperparamètres et leurs décisions sont parfois difficiles à interpréter. La prédiction peut aussi être lente, et l'obtention de probabilités nécessite une étape de calibrage supplémentaire.

Les SVM peuvent souffrir de surapprentissage lorsque leur modèle est trop complexe, ou de sous-apprentissage lorsqu'il est trop simple. Le réglage des hyperparamètres et la validation croisée permettent de trouver un bon équilibre et d'améliorer leur capacité à généraliser à de nouvelles données.

Références

[1] “Open Access Series of Imaging Studies (OASIS),” https://sites.wustl.edu/oasisbrains/, consulté le 21 octobre 2026. pages 3

[2] “XMedCon – main / homepage,” https://xmedcon.sourceforge.io/, consulté le 21 octobre 2026. pages 4

[3] “Local binary pattern for texture classification,” https://scikit-image.org/docs/stable/auto_examples/features_detection/plot_local_binary_pattern.html, documentation de scikit-image, version 0.26.0. Consulté le 22 octobre 2026. pages 5

[4] “Pipeline,” https://scikit-learn.org/stable/modules/generated/sklearn.pipeline.Pipeline.html, documentation de scikit-learn. Consulté le 22 octobre 2026. pages 5

[5] “SVC,” https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC.html, documentation de scikit-learn. Consulté le 22 octobre 2026. pages 7

[6] “GridSearchCV,” https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html, documentation de scikit-learn. Consulté le 22 octobre 2026. pages 8

[7] “StratifiedKFold,” https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.StratifiedKFold.html, documentation de scikit-learn. Consulté le 23 octobre 2026. pages 8